

# Aprendizagem automática

Sessão 6 - T

## Aprendizagem não supervisionada Redução da dimensionalidade

Ciência de Dados Aplicada

2023/2024


# Redução da dimensionalidade

- **Objetivo:** transformar dados de elevada dimensão numa representação de dimensão inferior, com o objetivo de captar os padrões e relações essenciais dos dados, minimizando a redundância e o ruído.
- **Porquê reduzir as dimensões?**
  - Simplifica a **análise e a visualização** de dados complexos;
  - Reduz a **complexidade computacional** e os requisitos de memória;
  - Ajuda a atenuar a **maldição da dimensionalidade**;
  - Melhora o **desempenho e a generalização do modelo**;
  - Melhora a **interpretabilidade** e a compreensão dos padrões de dados subjacentes;

# Redução da dimensionalidade

- Se tivermos apenas uma característica, podemos facilmente traçar os dados numa reta numérica.
- Mesmo com este gráfico simples, podemos ver diferenças entre as amostras 1, 2 e 3 e 4, 5 e 6.

	Característica 1
Amostra 1	10
Amostra 2	11
Amostra 3	8
Amostra 4	3
Amostra 5	1
Amostra 6	2



**Característica 1**

# Redução da dimensionalidade

- Agora podemos traçar os dados num gráfico bidimensional.

	Característica 1	Característica 2
Amostra 1	10	6
Amostra 2	11	4
Amostra 3	8	5
Amostra 4	3	3
Amostra 5	1	2.8
Amostra 6	2	1

Característica 2



# Redução da dimensionalidade



UNIVERSIDADE  
CATOLICA  
PORTUGUESA

BRAGA

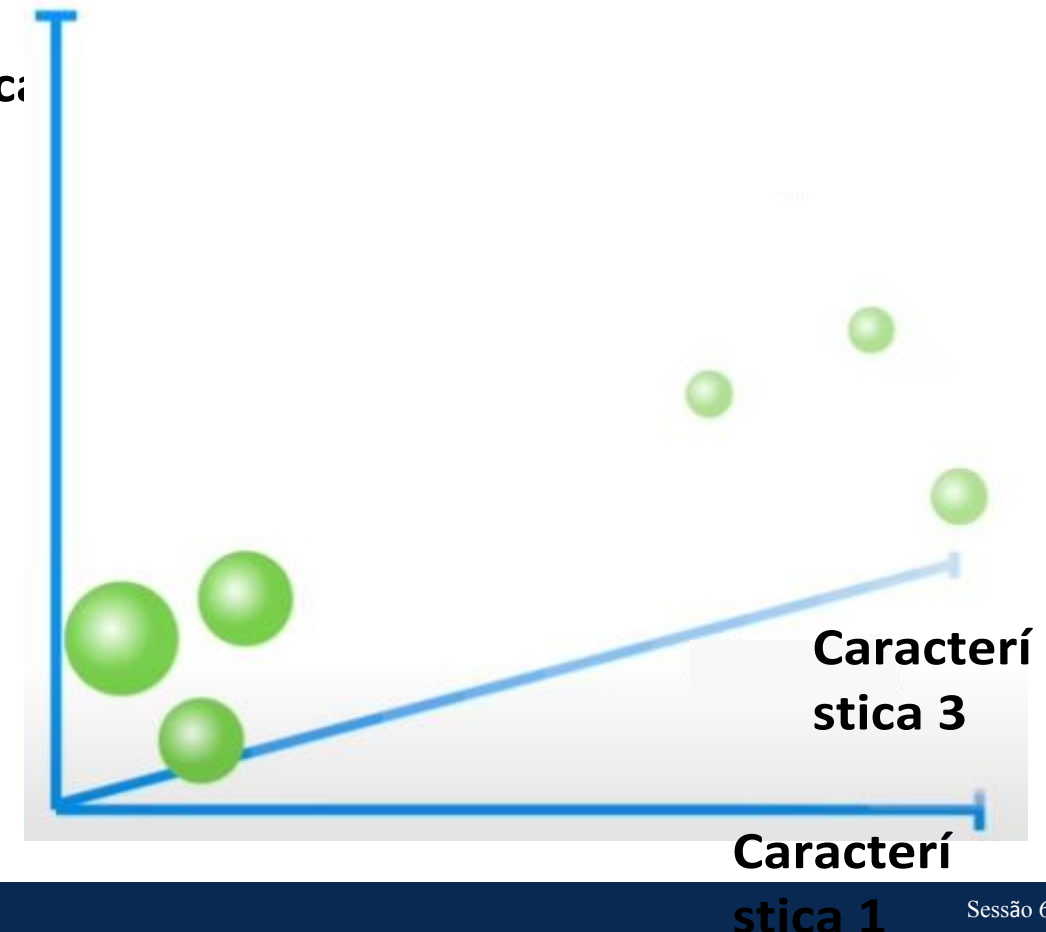
## Característica 1

# Redução da dimensionalidade

- Agora podemos traçar os dados num gráfico tridimensional.

	Característica 1	Característica 2	Característica 3
Amostra 1	10	6	12
Amostra 2	11	4	9
Amostra 3	8	5	10
Amostra 4	3	3	2.5
Amostra 5	1	2.8	1.3
Amostra 6	2	1	2

Característica



# Redução da dimensionalidade

- E quanto a 4 ou mais dimensões?

	Característica 1	Característica 2	Característica 3	Característica 4	...
Amostra 1	10	6	12	5	...
Amostra 2	11	4	9	7	...
Amostra 3	8	5	10	6	...
Amostra 4	3	3	2.5	2	...
Amostra 5	1	2.8	1.3	4	...
Amostra 6	2	1	2	7	...



# Análise de componentes principais (PCA)

- Identifica os **componentes principais**, que são novas variáveis que **captam a maior variação nos dados**;
- Estes **componentes são ortogonais** (não correlacionados) entre si, permitindo uma redução eficiente das dimensões;
- O **primeiro componente principal explica a quantidade máxima de variância** nos dados, seguido dos componentes subsequentes por ordem decrescente de variância explicada.




# PCA passo a passo

- Vamos começar com um exemplo simples com 2 características.

1.) Centrar os dados na média;

	Característica 1	Característica 2
Amostra 1	10	6
Amostra 2	11	4
Amostra 3	8	5
Amostra 4	3	3
Amostra 5	1	2.8

Característica 2



# PCA passo a passo


Amostra 6	2	1
-----------	---	---

# PCA passo a passo

1.) Centrar a média dos dados;

	Característica 1	Característica 2
Amostra 1	10	6
Amostra 2	11	4
Amostra 3	8	5
Amostra 4	3	3
Amostra 5	1	2.8
Amostra 6	2	1

Característica 2




Característica 1

# PCA passo a passo

1.) Centro médio dos dados;

	Característica 1	Característica 2
Amostra 1	10	6
Amostra 2	11	4
Amostra 3	8	5
Amostra 4	3	3
Amostra 5	1	2.8
Amostra 6	2	1

Característica 2

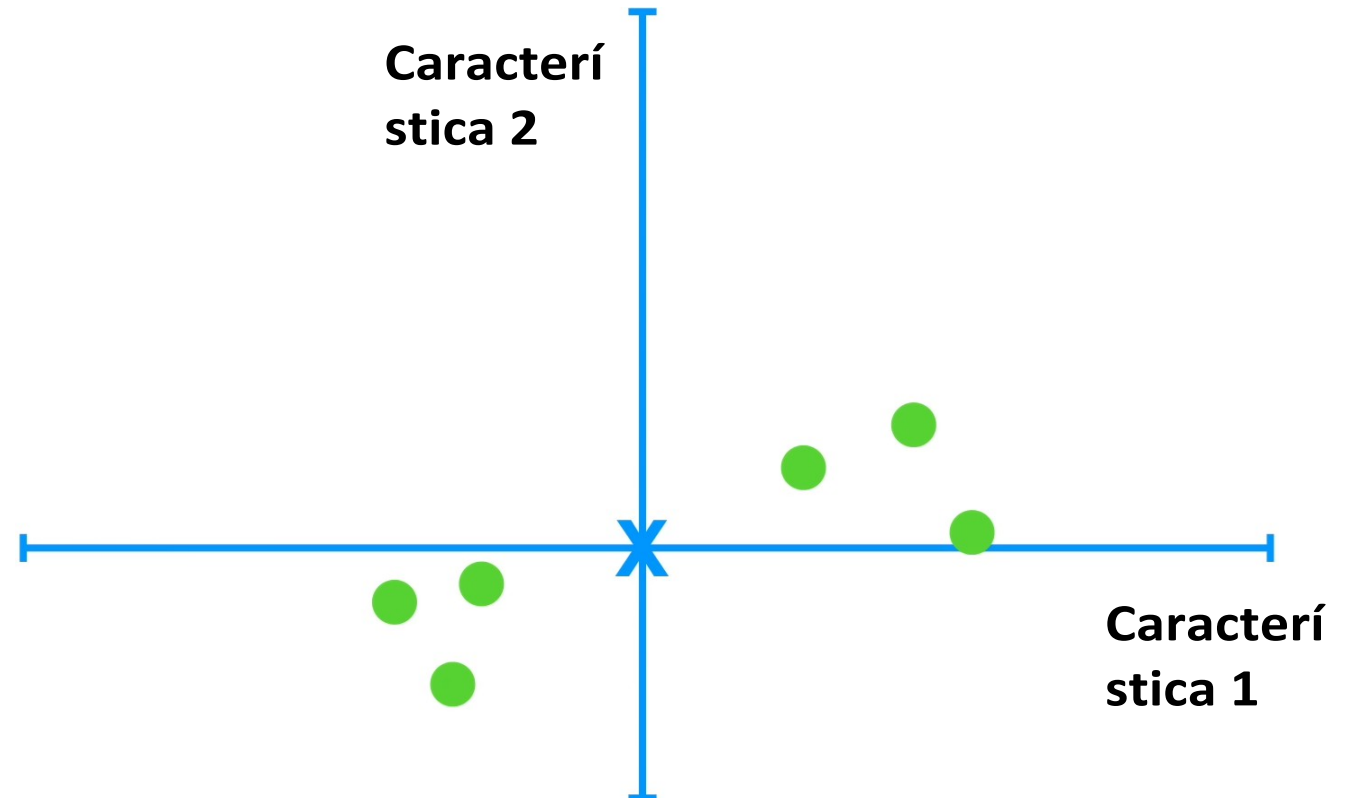


Característica 1

# PCA passo a passo


1.) Centro médio dos dados;

	Característica 1	Característica 2
Amostra 1	10	6
Amostra 2	11	4
Amostra 3	8	5
Amostra 4	3	3
Amostra 5	1	2.8
Amostra 6	2	1




# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição do valor singular (SVD).



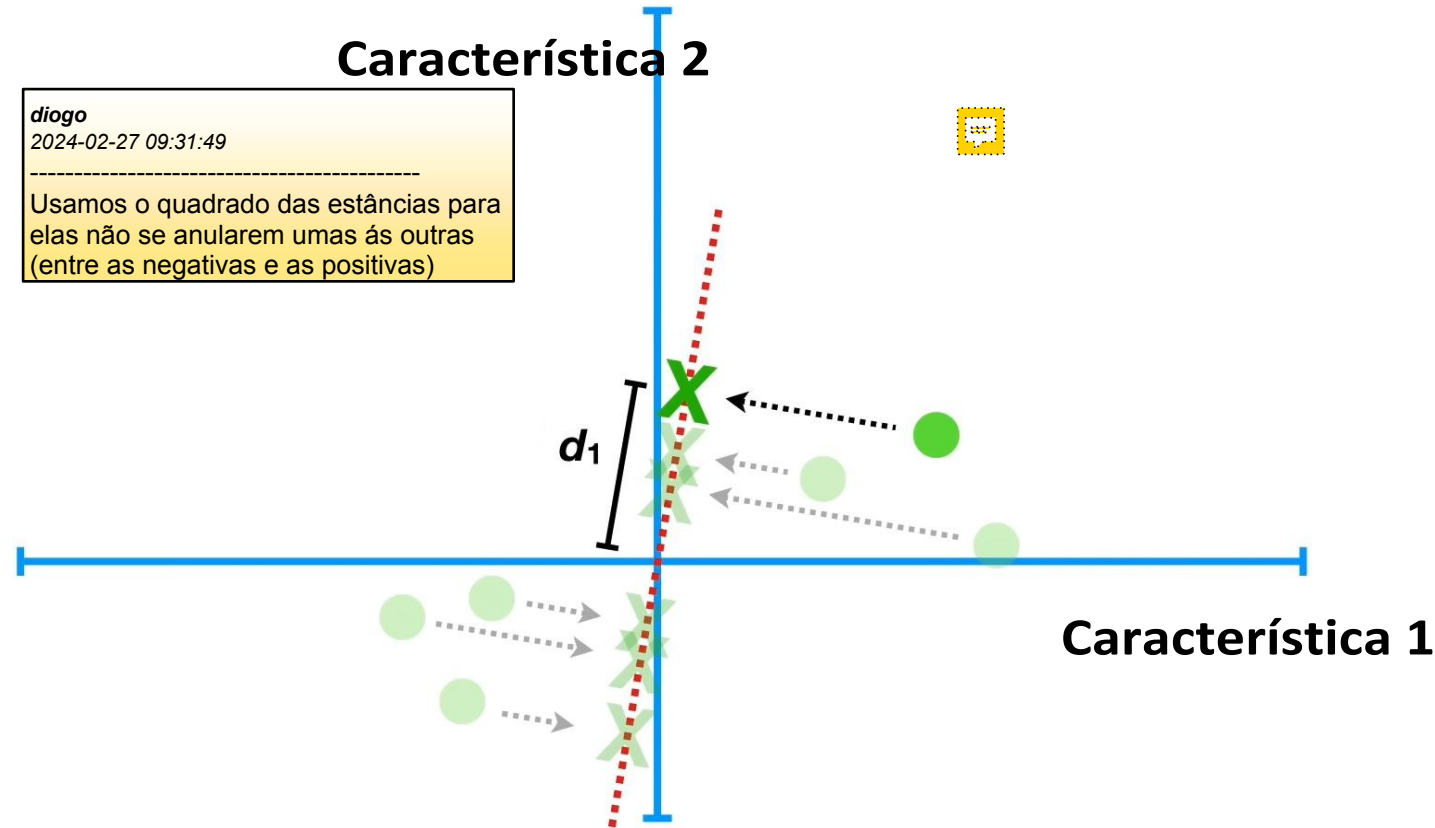
# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição em valores singulares (SVD).



# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição em valores singulares (SVD).




$$d_1^2 + d_2^2 + d_3^2 + d_4^2 + d_5^2 + d_6^2 = \text{soma das distâncias ao quadrado}$$



# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição em valores singulares (SVD).



$$d1^2 + d2^2 + d3^2 + d4^2 + d5^2 + d6^2 = \text{soma das distâncias}$$

# ao quadrado PCA passo a passo

A média da soma das distâncias ao quadrado para PC1 é designada por **Eigenvalue** para PC1.



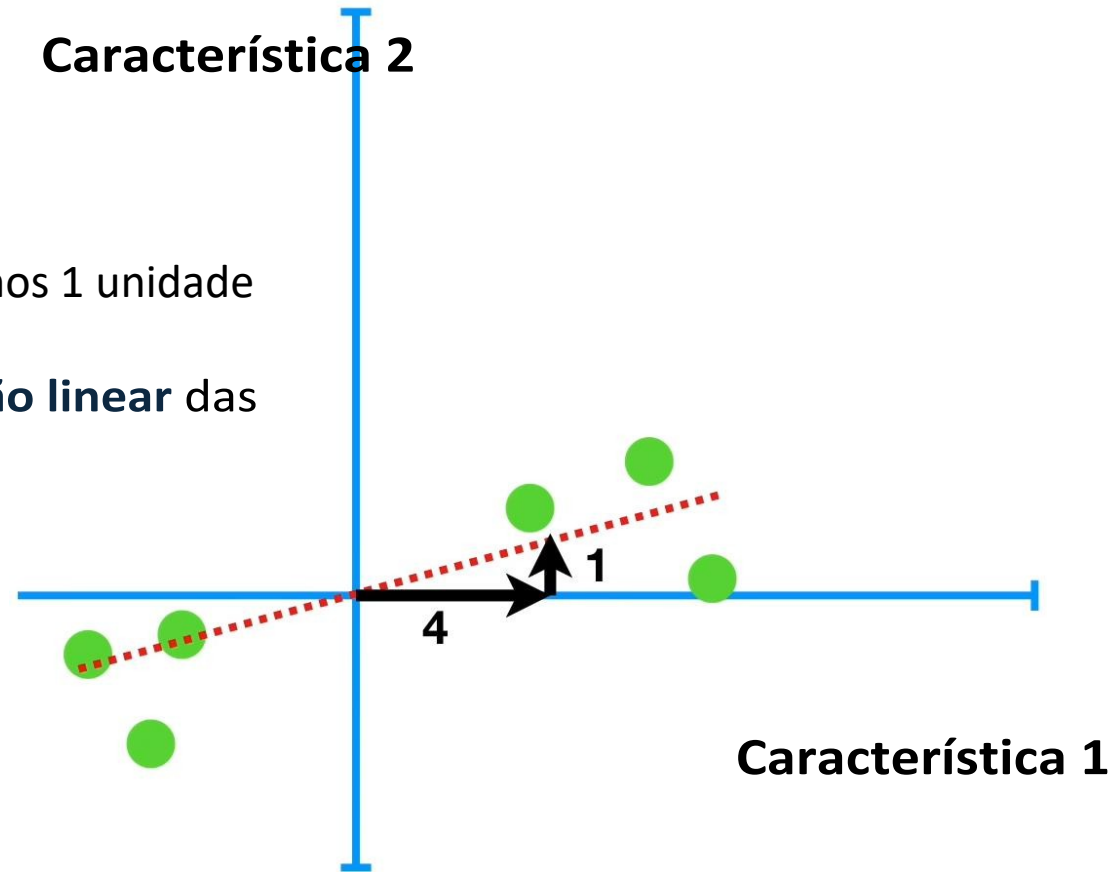
UNIVERSIDADE  
CATHOLICA  
PORTUGUESA  
BRAGA

# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição em valores singulares (SVD).

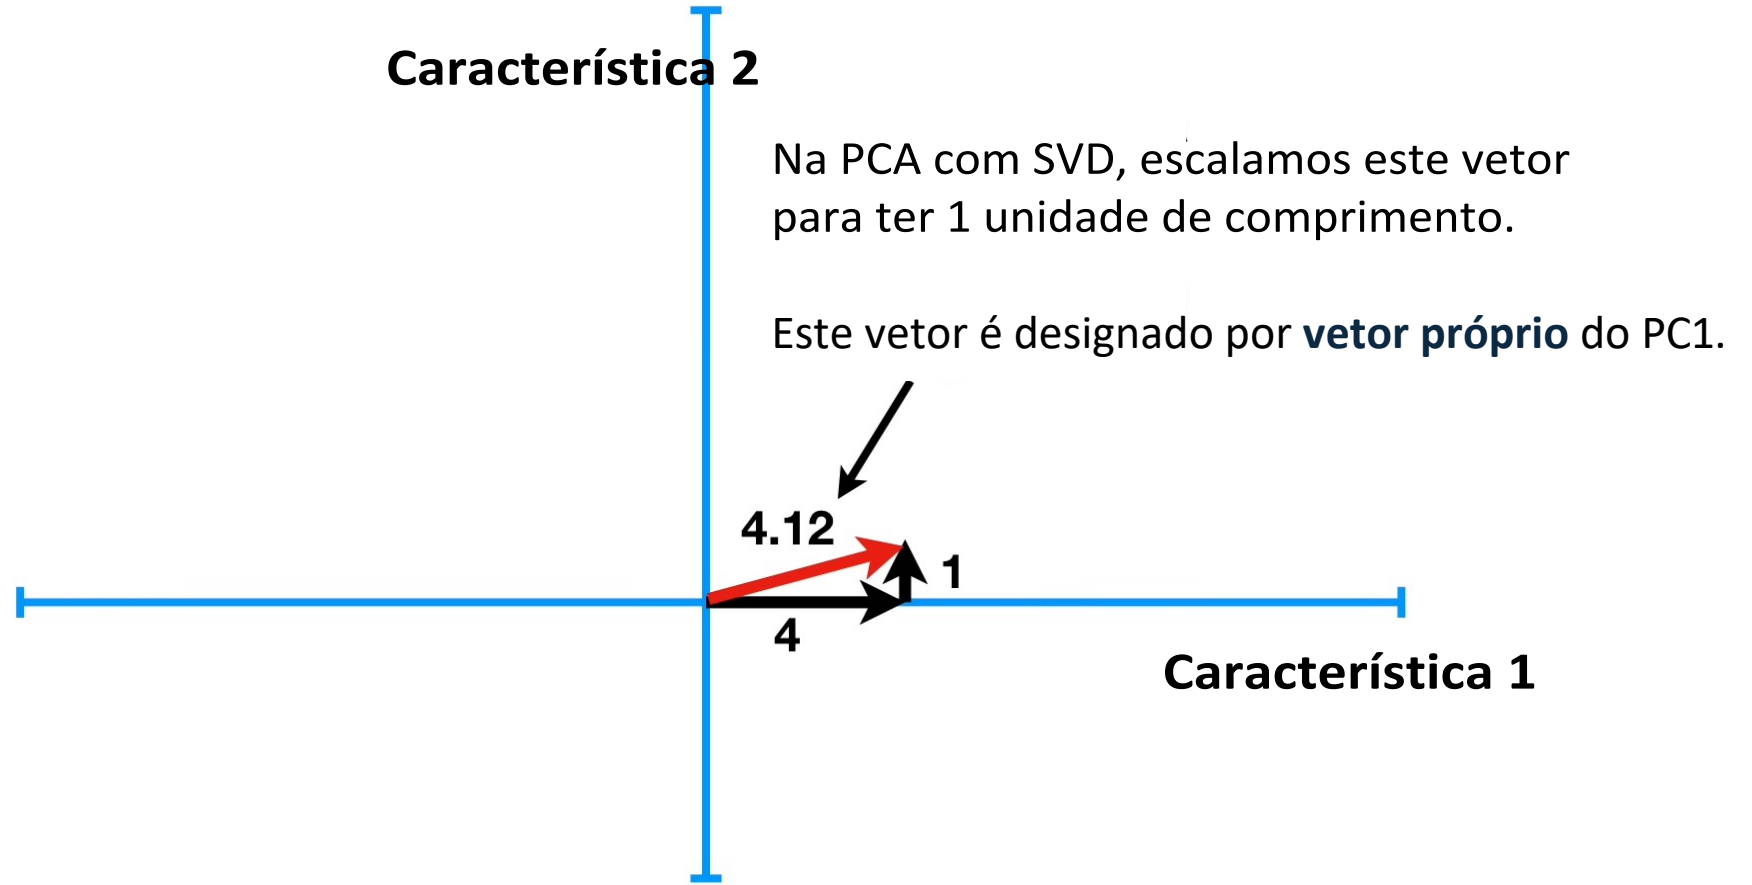
Digamos que o declive da reta é 0,25.

Para 4 unidades da característica 1 aumentamos 1 unidade na característica 2. O PC1 é uma **combinação linear** das características 1 e 2.



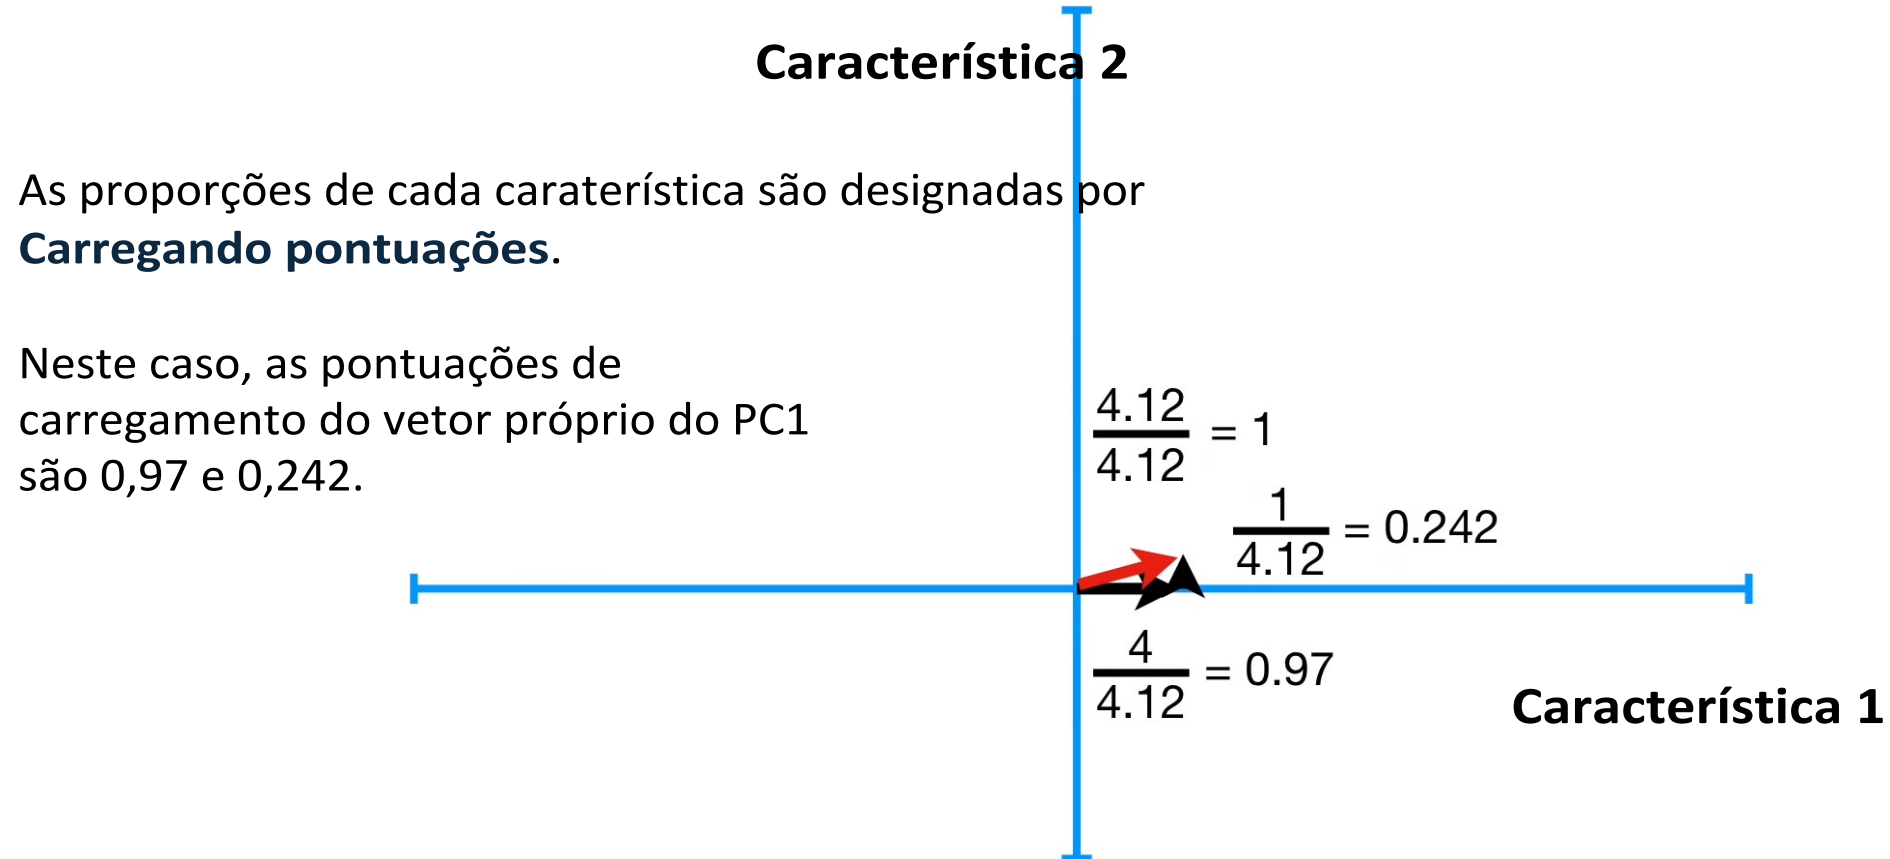
# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição em valores singulares (SVD).




# PCA passo a passo

2.) Calcular PC1 utilizando a decomposição do valor singular (SVD).




# PCA passo a passo

3.) Calcular o PC2 utilizando a decomposição do valor singular (SVD).




# PCA passo a passo

3.) Calcular o PC2 utilizando a decomposição do valor singular (SVD).



# PCA passo a passo


4.) Obter as coordenadas finais ao longo dos PCs.






# PCA passo a passo

4.) Obter as coordenadas finais ao longo dos PCs.



# PCA passo a passo


4.) Obter as coordenadas finais ao longo dos PCs.



# PCA passo a passo

4.) Obter as coordenadas finais ao longo dos PCs.


Podemos agora mapear os pontos projectados back para as amostras.



# PCA passo a passo

4.) Obter as coordenadas finais ao longo dos PCs.

Podemos agora mapear os pontos projectados back para as amostras.



# PCA - Variância Explicada


$$\frac{SS(\text{distances for PC1})}{n - 1} = \text{Eigenvalue for PC1}$$

$$\frac{SS(\text{distances for PC2})}{n - 1} = \text{Eigenvalue for PC2}$$


Digamos que o valor próprio para PC1 é 15 e para PC2 é 3.

A **variância explicada** do PC1 =  $15 / (15 + 3) = 0,83 = 83\%$

Para PC2 =  $3 / (15 + 3) = 0,17 = 17\%$



# PCA - Variância explicada - Scree Plot

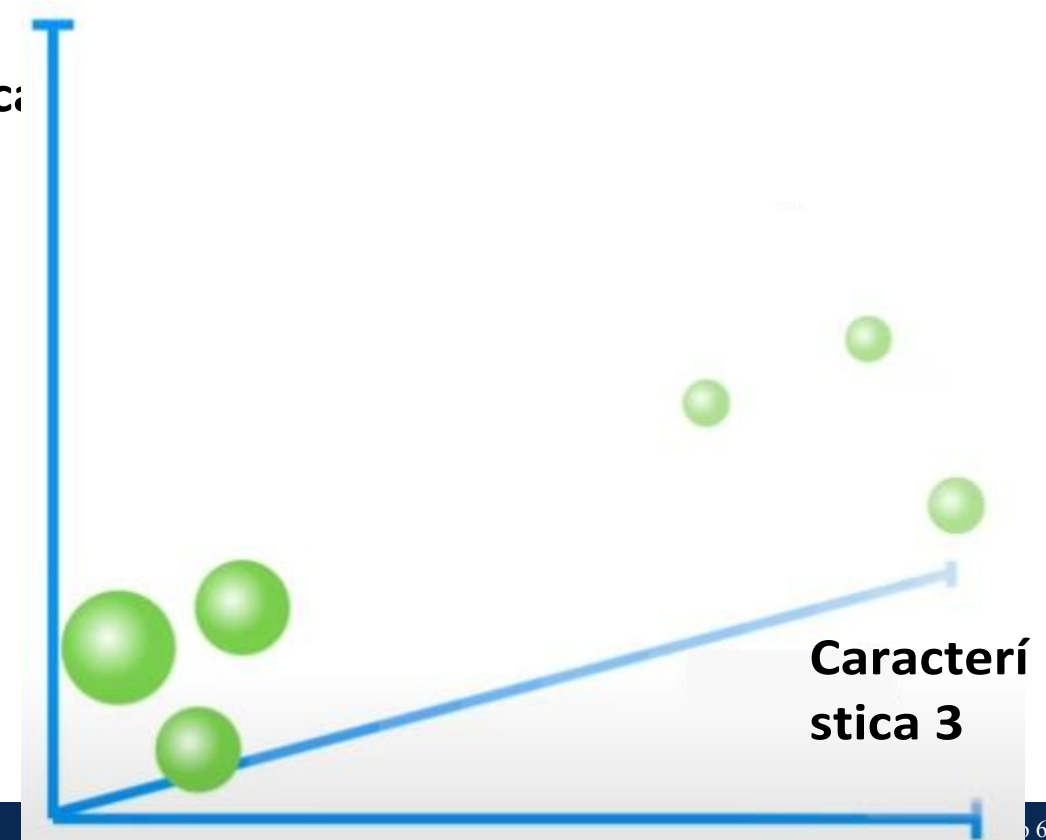


# PCA com mais recursos

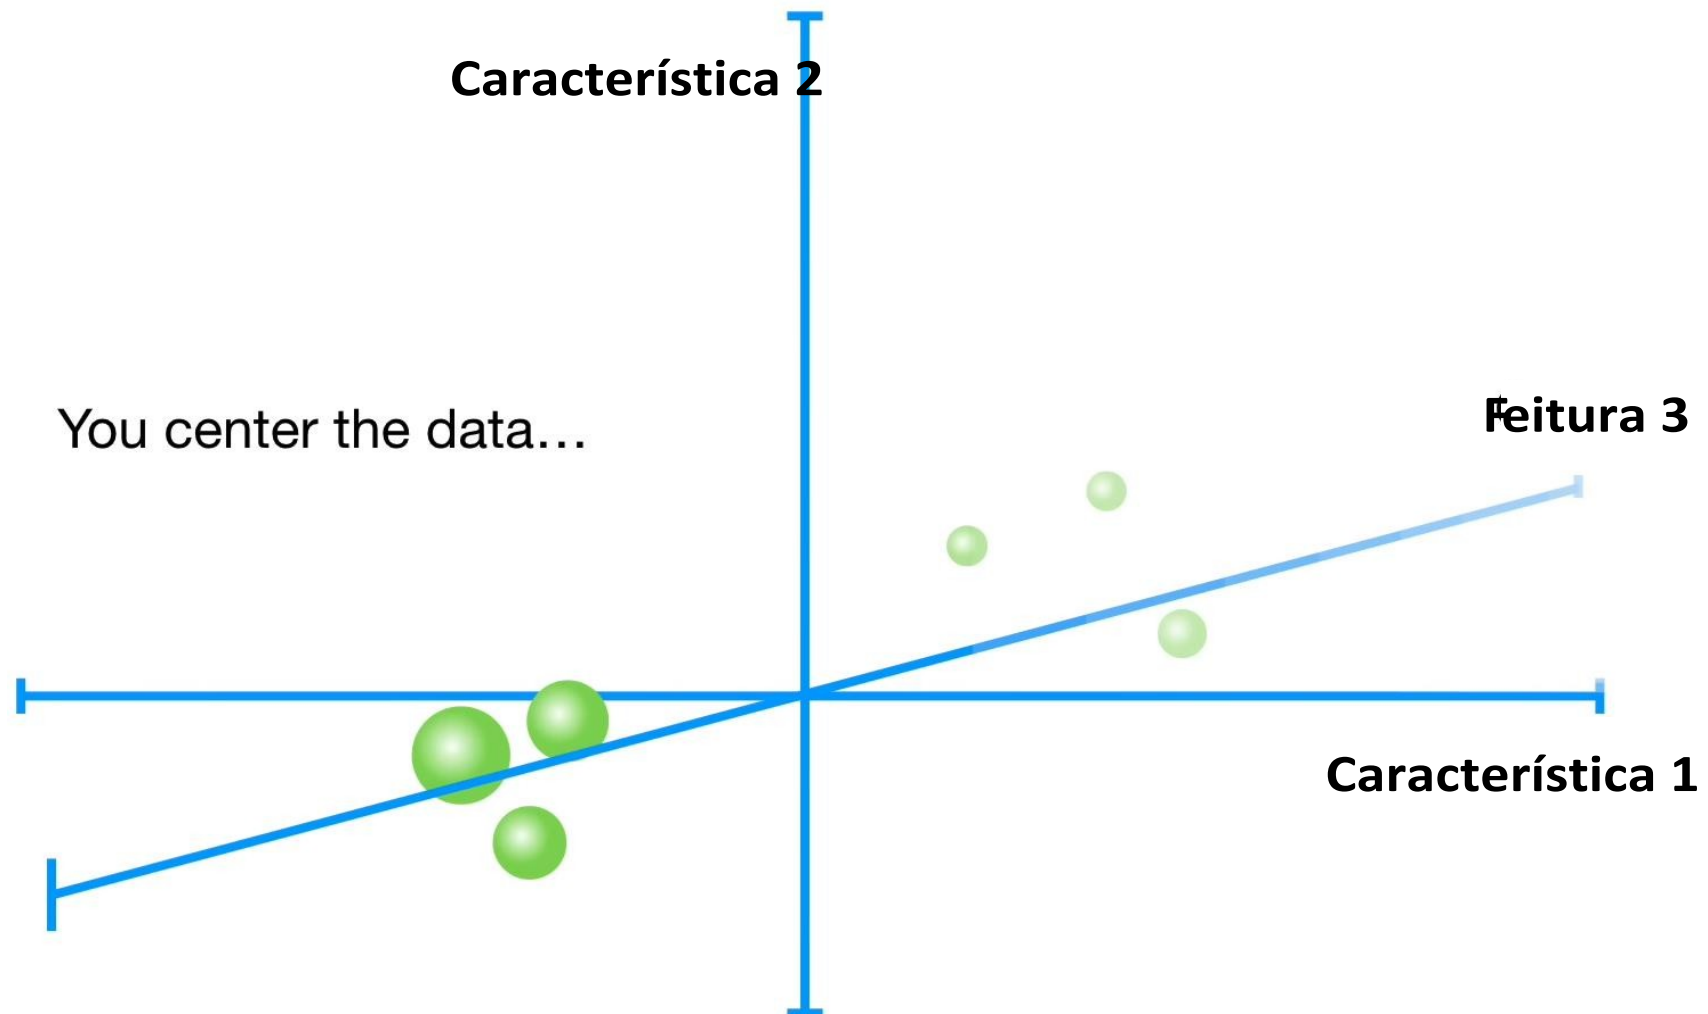
- PCA com 3 ou mais características é praticamente o mesmo que 2 características...

	Característica 1	Característica 2	Característica 3
Amostra 1	10	6	12
Amostra 2	11	4	9
Amostra 3	8	5	10
Amostra 4	3	3	2.5
Amostra 5	1	2.8	1.3
Amostra 6	2	1	2

Característica

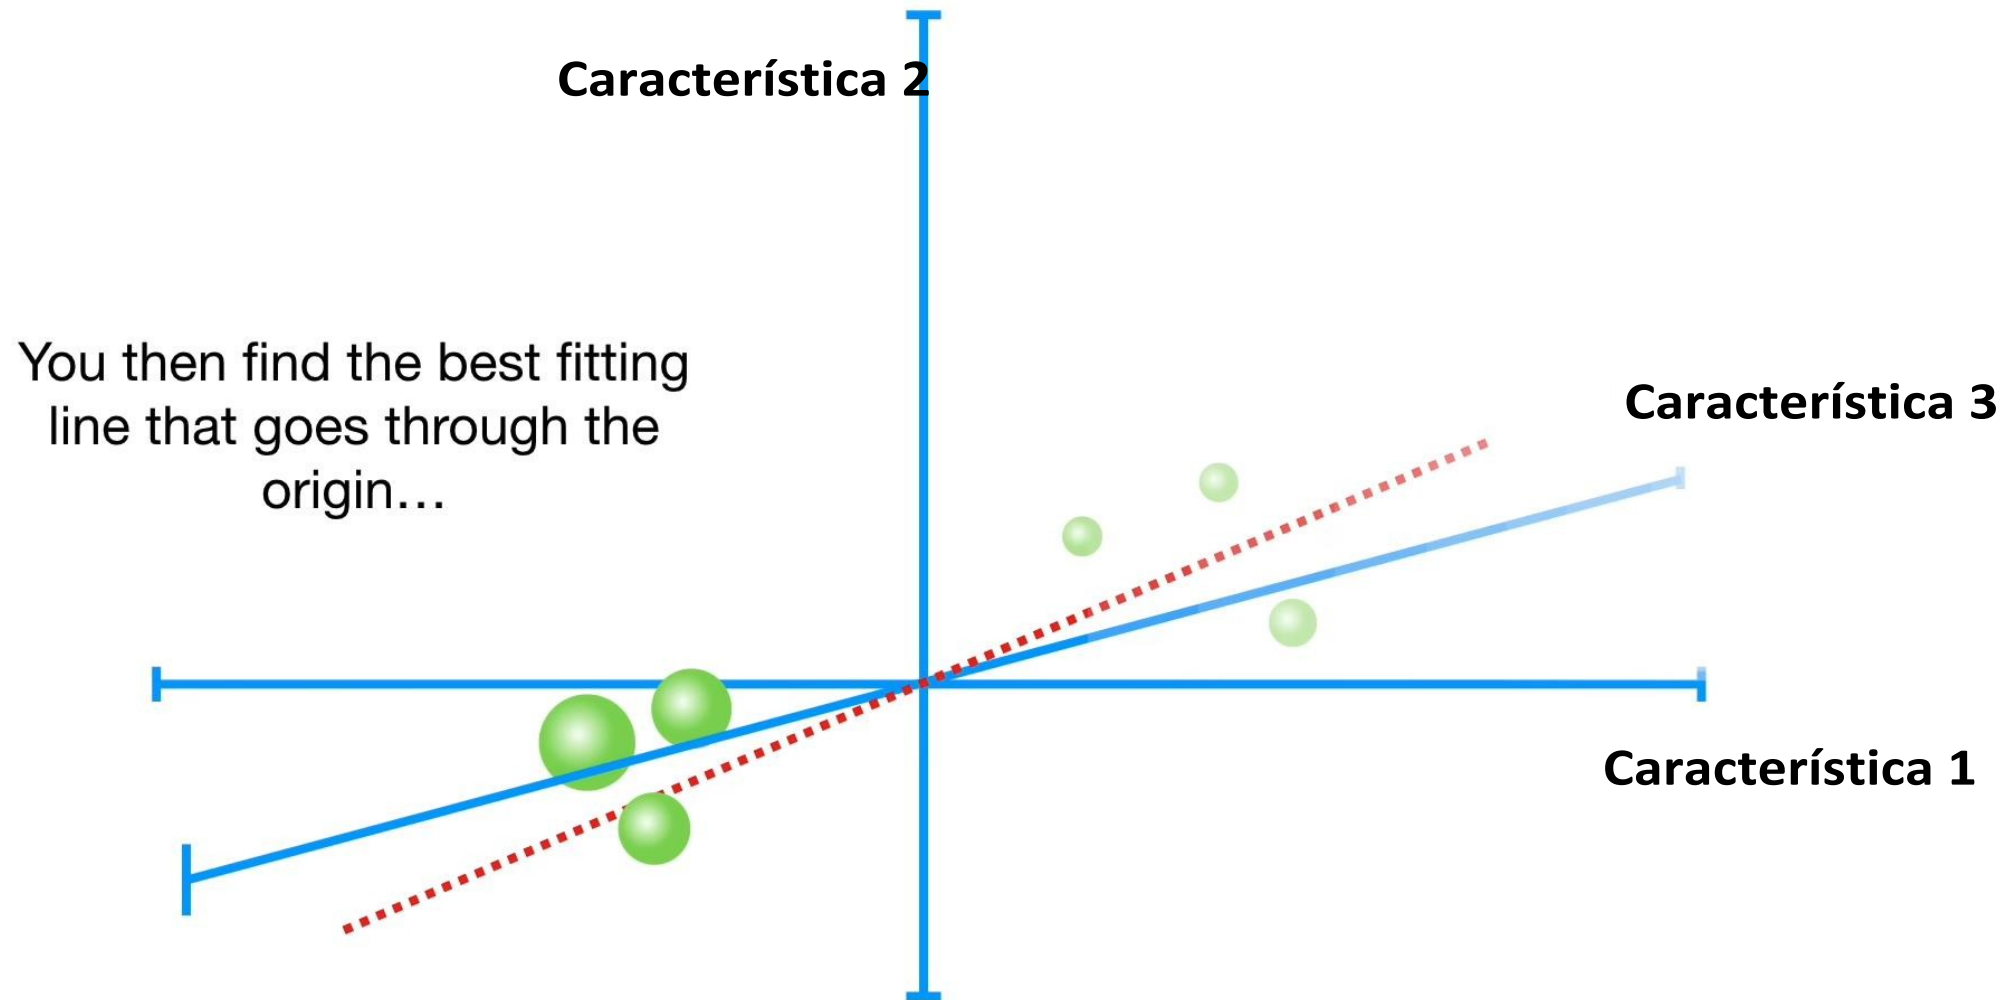


# PCA com mais recursos






# PCA com mais recursos



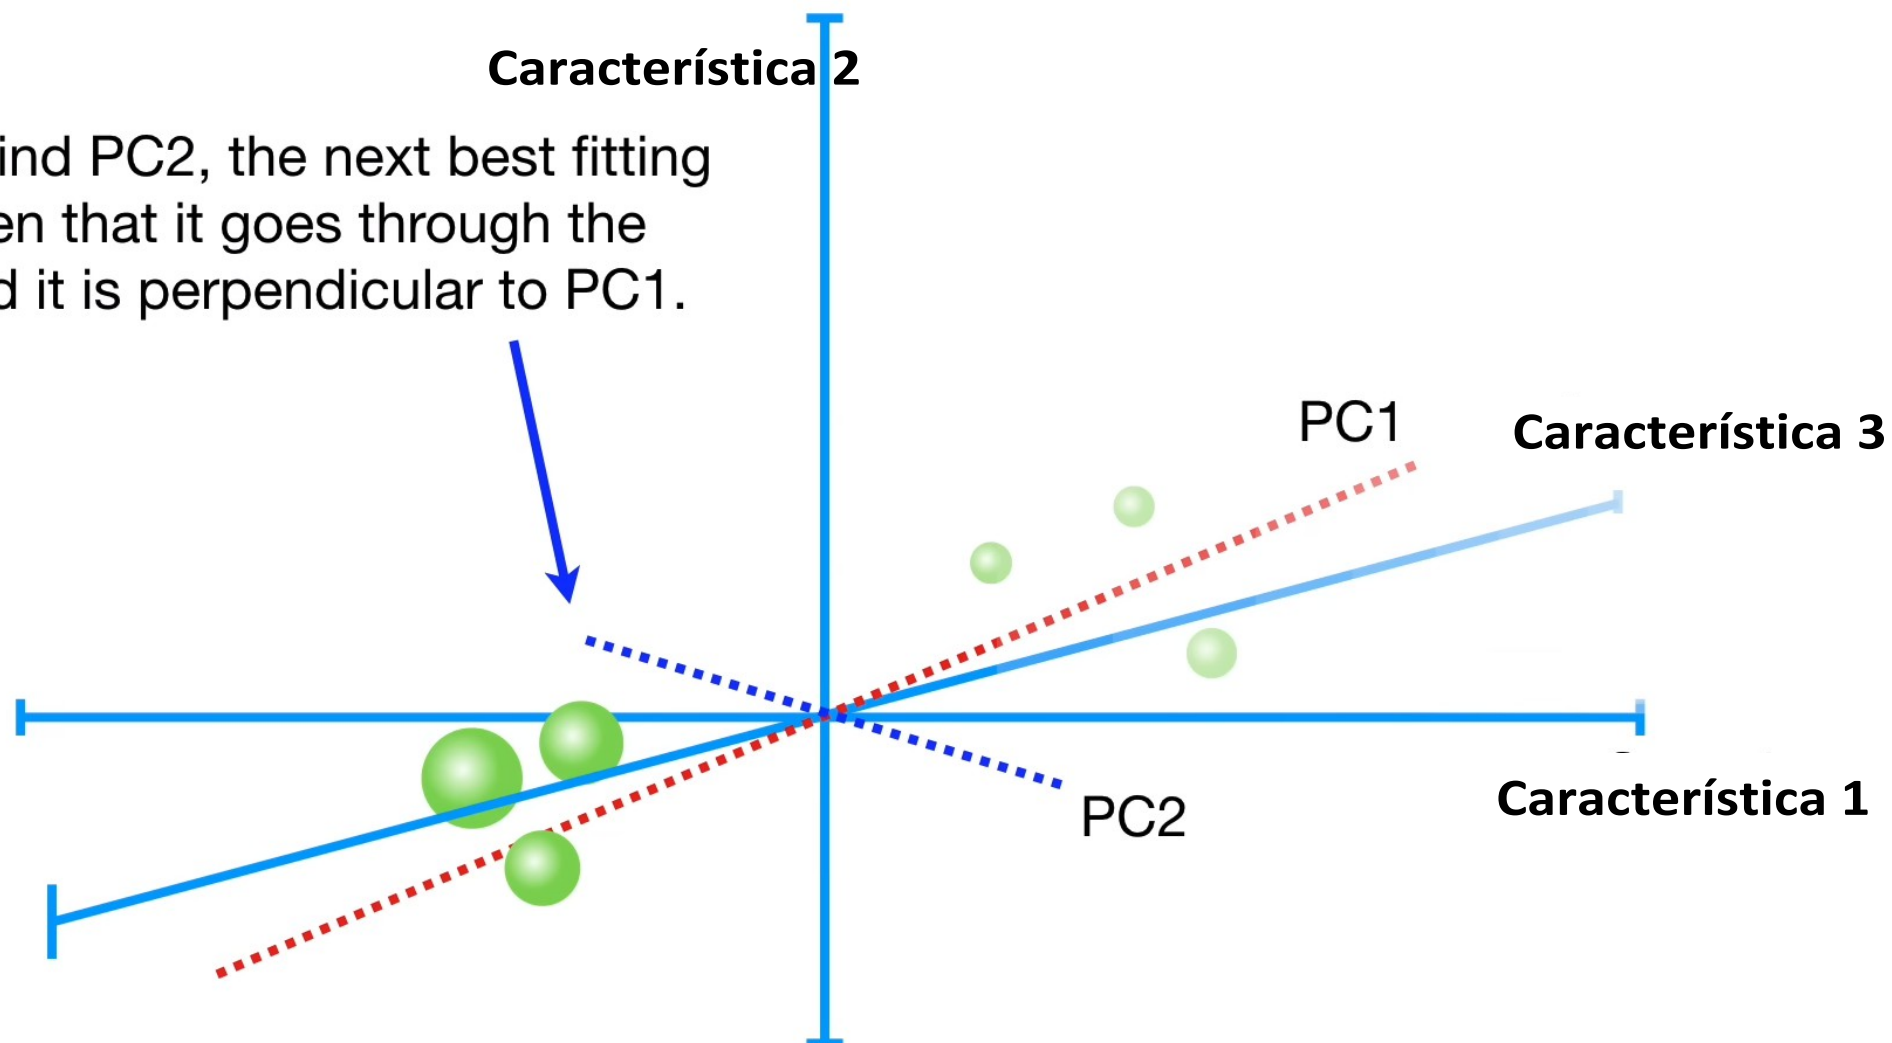
# PCA com mais recursos



# PCA com mais recursos



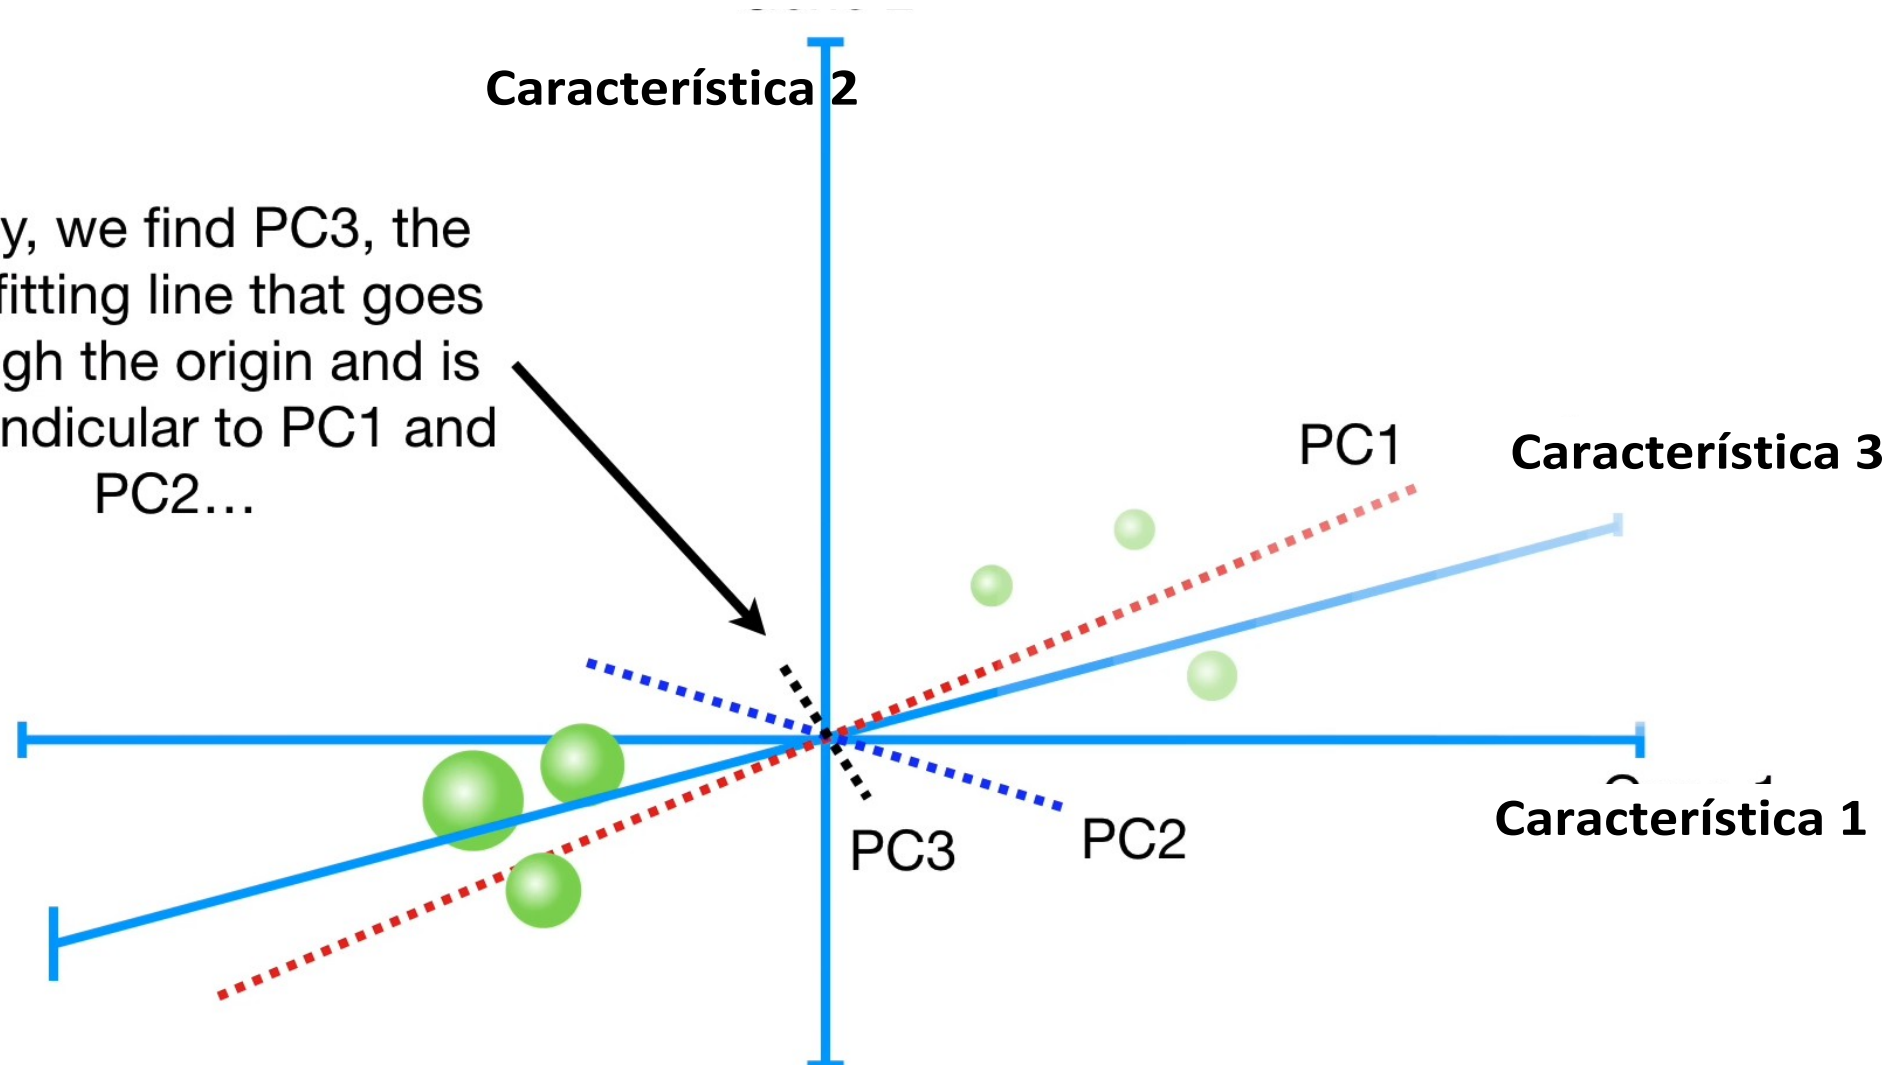
You then find PC2, the next best fitting line given that it goes through the origin and it is perpendicular to PC1.



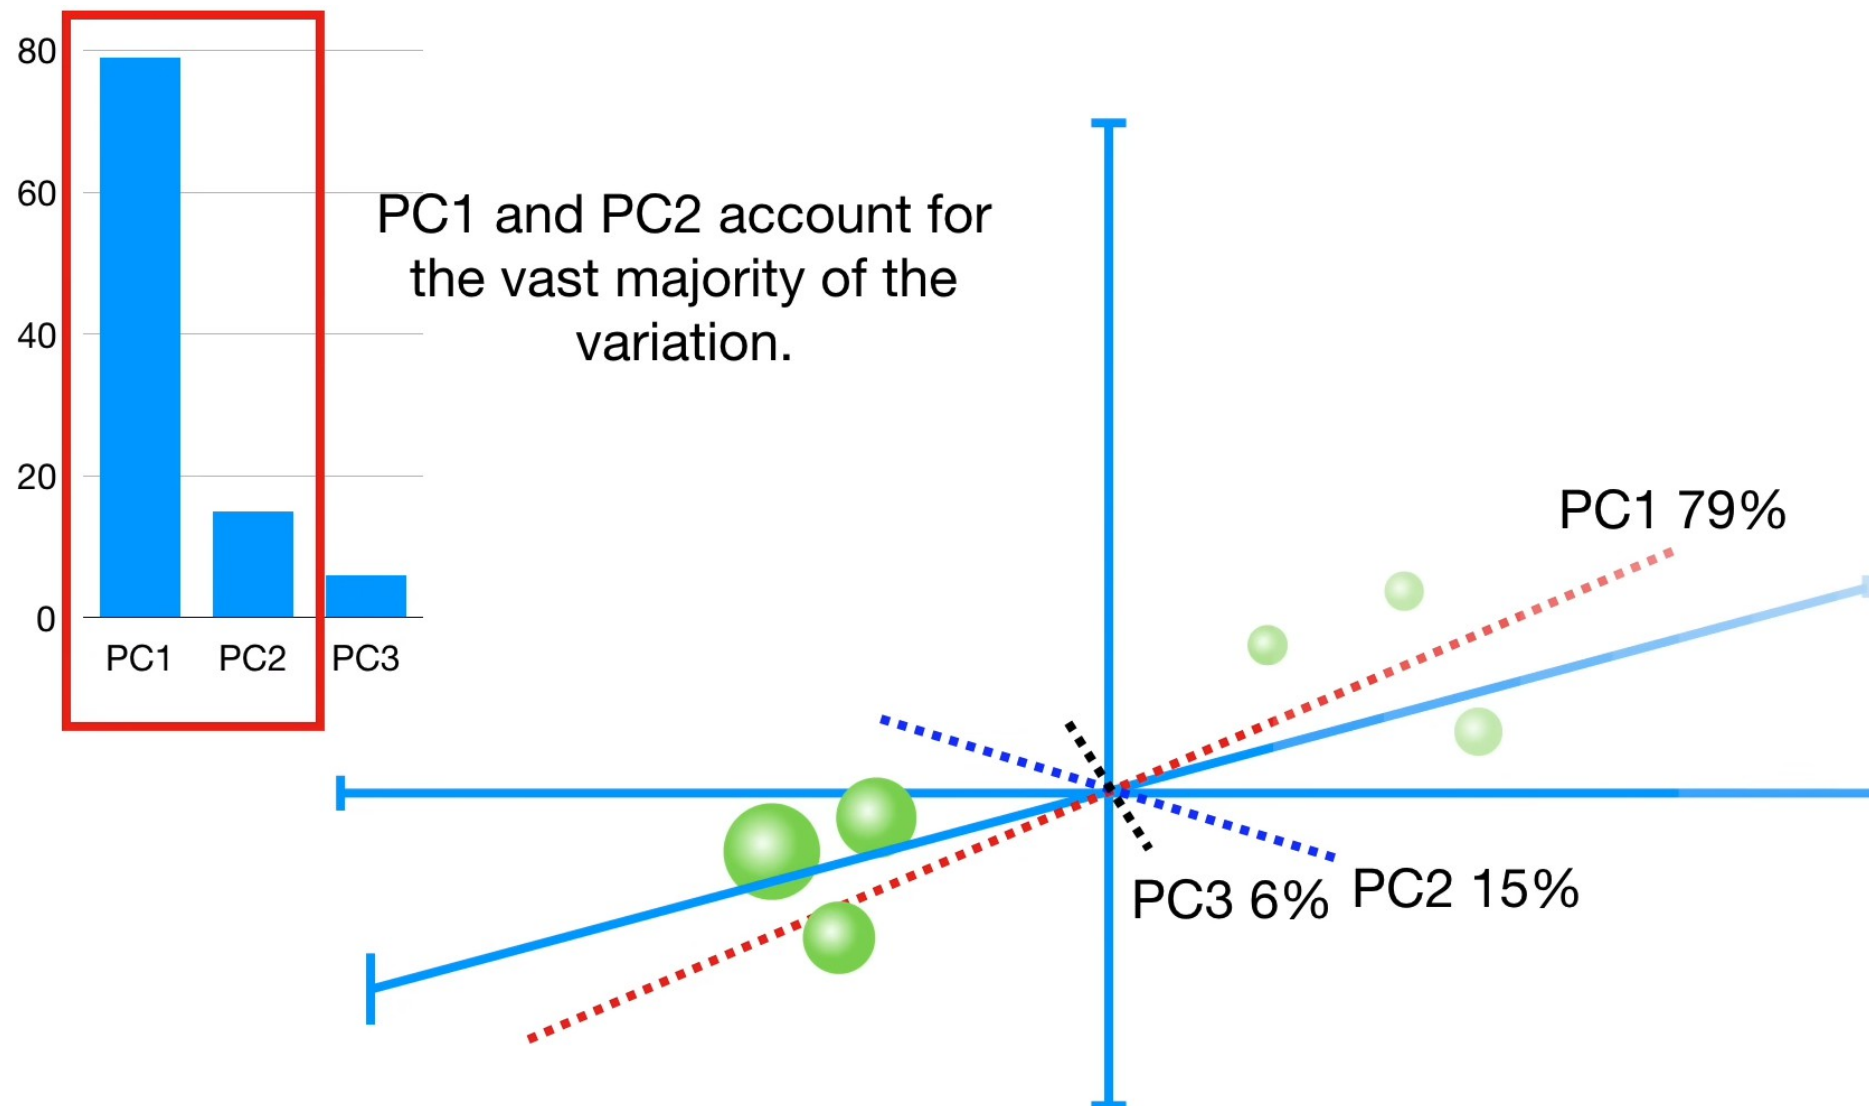
# PCA com mais recursos




Lastly, we find PC3, the best fitting line that goes through the origin and is perpendicular to PC1 and PC2...



# PCA com mais recursos

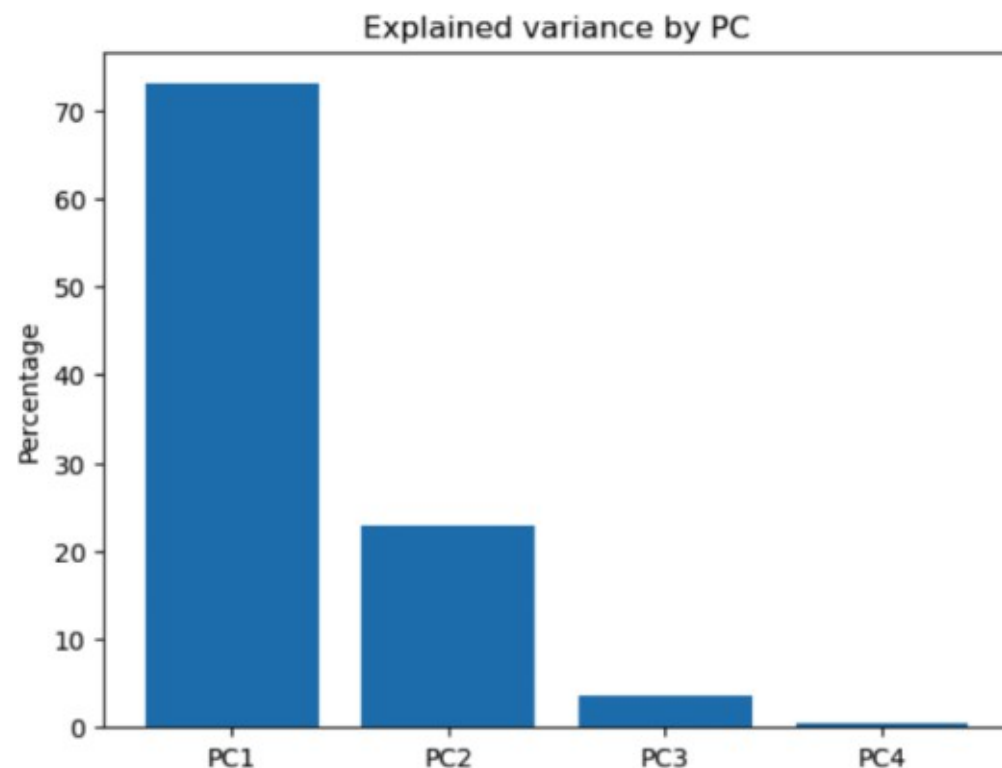


# PCA com mais recursos




**NOTE:** If the scree plot looked like this, where PC3 and PC4 account for a substantial amount of variation, then just using the first 2 PCs would not create a very accurate representation of the data.

# Exemplo de PCA com o conjunto de dados da íris



Graph showing the variance explained by each PC



Scores plot showing coordinates of the different flowers in the PC1/ PC2. Colours represent species, **which were not used in the PCA computations.**

# Terminologia PCA

- **Componente principal:** Combinações lineares de variáveis originais que captam a variância máxima nos dados.
- **Vetor próprio:** Direção no da característica espaço que define o principal componentes.
- **Valor próprio:** Escalar indicando a quantidade de variância explicada pelo seu vetor próprio correspondente.
- **Variância explicada:** Proporção da variância total dos dados explicada por cada componente principal.
- **Pontuação de carregamento:** Peso ou coeficiente atribuído a cada variável original na construção de componentes principais.



# Considerações finais da AdC

- **Relações não lineares:** A ACP pressupõe relações lineares entre variáveis, o que limita a sua eficácia na captação de padrões não lineares complexos; para esses casos, considerar técnicas não lineares como t-SNE ou UMAP.
- **Interpretabilidade:** A PCA cria novas combinações de características que podem ser difíceis de interpretar, tornando-a menos adequada quando é crucial manter a interpretabilidade das características individuais.
- **Dados esparsos:** O desempenho da PCA pode ser afetado por dados esparsos em que a maioria dos valores são zero ou estão em falta, o que leva a distorções na estrutura dos dados.
- **Excedentes:** A PCA é sensível a valores aberrantes, que podem distorcer os resultados; para conjuntos de dados com valores aberrantes, podem ser necessárias técnicas robustas de PCA para atenuar o seu impacto.
- **Escala dos dados:** A PCA é sensível à escala das características, por isso é importante padronizar ou normalizar os dados antes de aplicar a PCA para garantir que todas as

características contribuem igualmente para a análise.

# Outras técnicas de redução da dimensionalidade

## Escalonamento multidimensional (MDS)

- **Objetivo:** Reduzir dados de elevada dimensão para um espaço de dimensão inferior, preservando as relações entre pares, permitindo a visualização e a análise.
- **Abordagens:**
  - **MDS métrico:** Procura preservar as distâncias reais entre os pontos de dados no espaço de dimensão inferior, utilizando frequentemente algoritmos de otimização como a descida do gradiente.
  - **MDS não métrico:** centra-se na preservação da ordem de classificação das distâncias e não nos seus valores absolutos, o que o torna adequado para dados ordinais ou não quantitativos.



# Outras técnicas de redução da dimensionalidade

- Computacionalmente intensivo para grandes conjuntos de dados e sensível à entrada.

# Outras técnicas de redução da dimensionalidade

## Incorporação de vizinhança estocástica distribuída t (t-SNE)

- **Objetivo:** Reduzir dados de espaço de dimensão inferior para a a espaço, dando ênfase às relações locais entre os pontos de dados.
- **Abordagem:**
  - O t-SNE utiliza uma abordagem de mapeamento **não linear** que visa preservar **as semelhanças locais** no espaço de alta dimensão, modelando-as como probabilidades condicionais.
  - Minimiza a divergência entre as probabilidades condicionais nos espaços de alta dimensão e de baixa dimensão utilizando a otimização de descida gradiente.
- **Características principais:**
  - Enfatiza a preservação de estruturas locais, tornando-o eficaz para visualizar agrupamentos e estruturas múltiplas nos dados.
  - Particularmente útil para explorar relações complexas e não lineares em conjuntos de dados de elevada dimensão.

# Outras técnicas de redução da dimensionalidade

## Aproximação e Projeção Uniforme de Manifolds (UMAP)

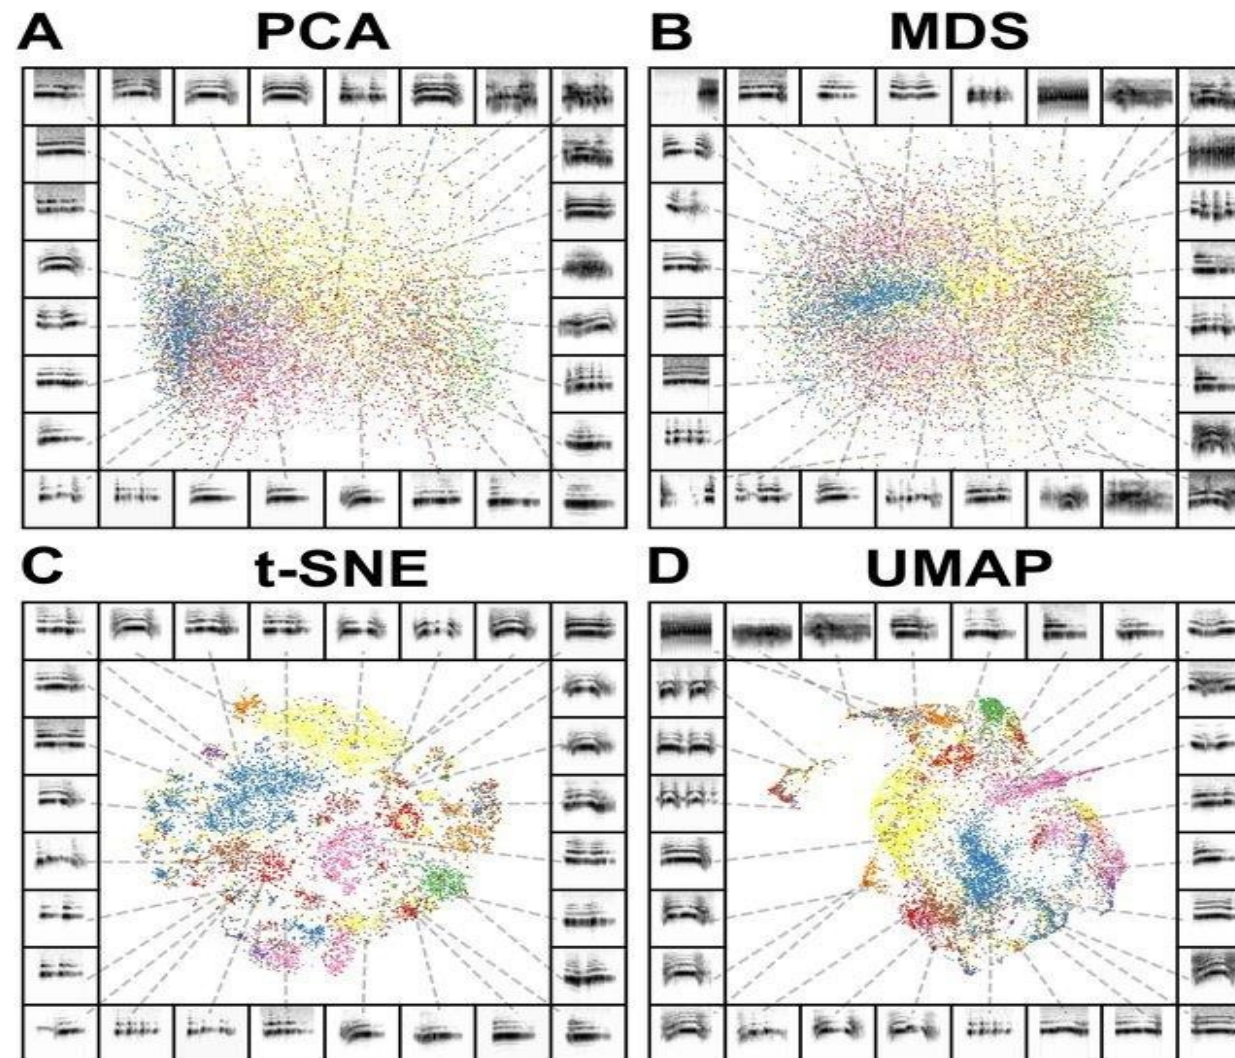
- **Objetivo:** Reduzir a dimensionalidade de dados de elevada dimensão, preservando a estrutura local e global, oferecendo um equilíbrio entre a preservação de **detalhes locais** e a **captura de padrões globais**.
- **Abordagem:**
  - O UMAP constrói um gráfico de alta dimensão que representa as relações locais entre os pontos de dados e otimiza a incorporação num espaço de dimensão inferior para corresponder à topologia do gráfico.
  - Utiliza uma combinação da teoria dos conjuntos difusos e da geometria Riemanniana para modelar a estrutura múltipla dos dados.
- **Características principais:**
  - Preserva a estrutura local e global, permitindo uma representação mais abrangente dos dados.
  - Oferece flexibilidade no equilíbrio entre a preservação de detalhes locais e a captura de padrões globais através da afinação de parâmetros.
  - Conhecido pela sua escalabilidade e eficiência, tornando-o adequado para grandes conjuntos de dados.

# PCA vs MDS vs tSNE vs UMAP



UNIVERSIDADE  
CATOLICA  
PORTUGUESA

BRAGA



Sainburg, T., Thielk, M., C Gentner, T. Q. (2020). Encontrar, visualizar e quantificar a estrutura latente em diversos repertórios vocais de animais. Em F. E. Theunissen (Ed.), PLOS Computational Biology (Vol. 16, Issue 10, p. e1008228). Biblioteca Pública da Ciência (PLOS). <https://doi.org/10.1371/journal.pcbi.1008228>

- Redução de dimensão: Uma visita guiada:  
[https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/FnT\\_dimensionReduction.pdf](https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/FnT_dimensionReduction.pdf)
- Oskolkov, N. (2022). Redução da dimensionalidade. Em Applied Data Science in Tourism (pp. 151-167). Springer International Publishing.  
[https://doi.org/10.1007/978-3-030-88389-8\\_9](https://doi.org/10.1007/978-3-030-88389-8_9)