

# Aprendizagem automática

Sessão 11 - T


## Modelos lineares

Ciência de Dados Aplicada

2023/2024

# Modelos lineares

- Os modelos lineares são uma classe de algoritmos de aprendizagem automática que modelam a relação entre variáveis dependentes e independentes utilizando **uma aproximação linear**.
- **Características principais:**
  - Fácil de interpretar e aplicar;
  - **Eficiente** para grandes conjuntos de dados devido à computação linear;
  - Pode ser utilizado tanto para **regressão** tarefas de **classificação**.



# Modelos lineares

- Um modelo linear é uma **representação matemática** de uma relação entre uma variável dependente  $y$  e uma ou mais variáveis independentes  $x_1, x_2, \dots, x_n$ , assumindo-se **que esta relação é linear**.
- Matematicamente, representa-se da seguinte forma:


$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$  Onde  $y$  é a **variável dependente**,  
 $x_1, x_2, \dots, x_n$  são as **variáveis independentes**,  $\beta_0$  é a **interceção**,  
 $\beta_1, \beta_2, \dots, \beta_n$  são os **coeficientes** e  
 $\epsilon$  é o **termo de erro**.

# Problemas não lineares





## Linearly separable

A linear decision boundary that separates the two classes exists



## Not linearly separable

No linear decision boundary that separates the two classes perfectly exists



<https://vitalflux.com/how-know-data-linear-non-linear/>

- **Limitações:** Em casos não lineares, os modelos lineares podem ser insuficientes...



# Modelos lineares

- **Regressão Linear Simples**
- **Regressão Linear Múltipla**
- **Regressão polinomial**
- **Regressão logística**

# Regressão Linear Simples

- A regressão linear simples modela a relação entre **uma variável independente e uma variável dependente**. A equação para uma regressão linear simples é:

A interceção - uma constante


Variável independente

Componente de erro

Variável dependente

Coefficient\Weight\Slope - controla a contribuição de x para y

$$y = \beta_0 + \beta_1 x + \epsilon$$



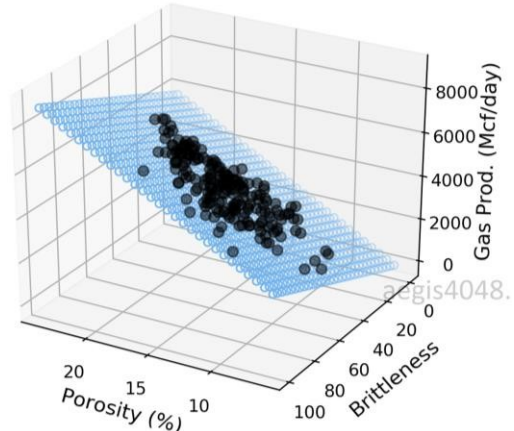
# Regressão Linear Múltipla

- A regressão linear múltipla alarga a regressão linear simples para incorporar **múltiplas variáveis independentes**. A equação para a regressão linear múltipla é:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$$

Diagram illustrating the components of the multiple linear regression equation:

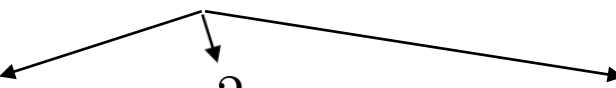
- Variável dependente**: Points to  $y$ .
- A interceção - uma constante**: Points to  $\beta_0$ .
- Variáveis independentes**: Points to  $x_1, x_2, \dots, x_n$ .
- Componente de erro**: Points to  $\epsilon$ .
- Coefficients\Weights\Slopes - controla a quantidade de cada x contribui para y**: Points to  $\beta_1, \beta_2, \dots, \beta_n$ .



# Regressão polinomial

- A regressão polinomial consiste em ajustar uma curva aos dados através da introdução de **termos polinomiais**. A equação para a regressão polinomial é:

Termos polinomiais

$$y = \beta_0 + \beta_1 x_1^1 + \beta_2 x_2^2 + \dots + \beta_n x_n^n + \epsilon$$



- NOTA: O termo "linear" na regressão linear refere-se à **linearidade dos coeficientes**, não necessariamente à linearidade da relação entre as variáveis independentes e dependentes.
- Na regressão polinomial, embora a **relação entre as variáveis seja modelada através de uma função polinomial** (que pode parecer curva), o processo de estimativa continua a ser linear em relação aos coeficientes.



# Regressão polinomial

Termos polinomiais

$$y = \beta_0 + \beta_1 x_1^1 + \beta_2 x_2^2 + \dots + \beta_n x_n^n + \epsilon$$



# Regressão linear

- **Função de custo:** Erro quadrático médio (MSE)

$$J(\beta) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$


$\hat{y}^{(i)}$  → Valor previsto  
                    dado por:  
                    ↓  
 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$

$y^{(i)}$  → Valor real

- **J** é uma função dos coeficientes do modelo  $\beta_0, \beta_1, \dots, \beta_n$
- Objetivo: identificar os coeficientes do modelo que **minimizam J**

# Regressão logística


- A regressão logística é utilizada para a **classificação binária**.
- Modela a **probabilidade de o resultado pertencer a uma determinada classe** utilizando a função logística, também conhecida como **função sigmoide**.



$$f(x) = \frac{1}{1 + e^{-(x)}}$$

# Regressão logística

- A classe prevista é dada pela **aplicação da função sigmoide ao resultado da regressão linear**.
- Dá-nos a **probabilidade** de  $y$  (resultado) ser 1 para o exemplo  $x$ .



$$f(x) = \frac{1}{1 + e^{-(x)}}$$

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

# Regressão logística

- Treinar **modelos "binários"** separados para cada classe;
- Tratar **as outras classes como uma entidade única** durante a formação;
- **Cada modelo estima a probabilidade** de o exemplo pertencer a uma classe;
- Aplicar todos os modelos, **selecionar a classe com mais elevada probabilidade prevista.**

# Regressão logística - Multiclasse

- **Função de custo:**

$$J(\beta) = \begin{cases} -\log(\hat{y}) & \text{if } y = 1 \\ -\log(1 - \hat{y}) & \text{if } y = 0 \end{cases}$$

- **Exemplo:**

- Se rótulo verdadeiro  $y=1$ , previsão= $0,8$ , erro =  $-\log(0,8)$  , erro baixo
- Se rótulo verdadeiro  $y=0$ , previsão= $0,8$ , erro =  $-\log(1 - 0,8)$ , erro elevado

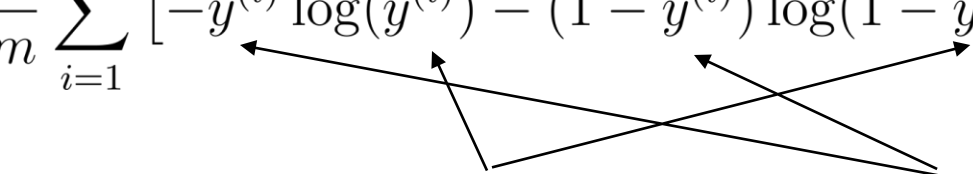
- **Combinando, obtemos:**

$$J(\beta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(\hat{y}^{(i)}) - (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})]$$

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

Valor previsto dado por:  $\hat{y}^{(i)}$

Valor real:  $y^{(i)}$



# Estimativa dos parâmetros (coeficientes) $\beta$

- A estimativa dos parâmetros consiste em determinar os **valores dos coeficientes**  $(\beta_1, \beta_2, \dots, \beta_n)$  que **melhor ajustam o modelo** aos dados de treino.
- Este processo envolve encontrar o parâmetros parâmetros que **minimizar uma função de perda predefinida**.
- Para modelos lineares, podemos utilizar o **método analítico dos mínimos quadrados**, minimizando a função de erro **MSE**.

- Podem também ser utilizados outros **métodos iterativos**, como a **descida do gradiente**.



# Regressão Linear - Mínimos Quadrados

- Método algébrico que envolve a resolução de um **sistema de equações**:

$$\frac{\partial}{\partial \beta_j} J(\beta) = 0, j = 1, \dots, n$$

$$\beta = (X^T X)^{-1} X^T y$$

↑  
Versão matricial

X consiste nos dados de treino

+

primeira coluna com uns (para ter em conta o beta zero)

# Regressão linear\Logística - Gradiente Descendente



UNIVERSIDADE  
CATOLICA  
PORTUGUESA

BRAGA

- Só pode ser aplicado se a **função de custo for diferenciável**.
- **Método iterativo** que, em cada iteração, altera os valores dos parâmetros de modo a minimizar o erro entre as previsões e as etiquetas verdadeiras.

$$\beta_j := \beta_j - \alpha \frac{\partial}{\partial \beta_j} J(\beta)$$

Taxa de aprendizagem

Os parâmetros são actualizados da seguinte

$$\beta_j := \beta_j - \alpha \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$


forma:




# Mínimos quadrados vs Gradiente Descendente

- Os mínimos quadrados garantem **uma solução óptima**. A descida de gradiente pode **não convergem / ficam presos** em óptimos locais.
- Os mínimos quadrados são adequados e **computacionalmente** eficientes para pequenos conjuntos de dados;
- A descida de gradiente é adequada para **grandes conjuntos de dados** e pode tratar **modelos não lineares**.


# Sobreajuste em modelos lineares



Underfitting:  
Insufficient model  
complexity



“Adequate” model  
complexity




Overfitting:  
Excessive complexity

# Sobreajuste em modelos lineares



UNIVERSIDADE  
CATOLICA  
PORTUGUESA


BRAGA



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$


$g$  = sigmoid function

Underfitting:  
Insufficient model  
complexity



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$

"Adequate" model  
complexity



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$$

Overfitting:  
Excessive complexity



# Sobreajuste em modelos lineares

- Nos modelos lineares, como a regressão linear simples ou a regressão linear múltipla, **o sobreajuste não envolve curvas ou superfícies complexas que se dobram para se ajustarem aos dados.**
- Em vez disso, implica que o modelo linear **capte o ruído ou flutuações irrelevantes nos dados**, o que pode acontecer quando o modelo é demasiado complexo em relação à quantidade de dados disponíveis.
- Os modelos lineares são propensos ao sobreajuste nos casos em que o **número de características é elevado** (especialmente

# Sobreajuste em modelos

**lineares** quando comparado com o número de exemplos).






# Ultrapassar o sobreajuste em modelos lineares

- Reduzir o número de características (coeficientes) - seleção de características.
- Regularização: Mantém todas as características, tentando reduzir a magnitude dos valores dos parâmetros.
  - Regularização L1 (**regressão Lasso**)
  - Regularização L2 (**regressão de cumeeira**)
  - **Redes elásticas** - utilizar a regularização L1 e L2

# Regressão de cumeeira

- Ideia: **penalizar valores elevados dos parâmetros** (coeficientes) na função de custo.

$$J(\beta) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}(i) - y^{(i)})^2 + \lambda \sum_{j=1}^n \beta_j^2 \right]$$



Parâmetro de regularização:  
- valores mais elevados penalizam mais os valores dos parâmetros

Se for demasiado elevado:  
risco de subadaptação Se for  
demasiado baixo: risco de  
sobreadaptação

# Regressão de cumeeira

- Método analítico (mínimos quadrados):

$$\beta = \left( X^T X + \lambda \begin{bmatrix} 0 & & & \\ & 1 & & \\ & & 1 & \\ & & & \ddots \\ & & & & 1 \end{bmatrix} \right)^{-1} X^T y$$

# Regressão de cumeeira

- Descida de gradiente:

$$\beta_0 := \beta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_0^{(i)}$$

$$\beta_j := \beta_j \left(1 - \alpha \frac{\lambda}{m}\right) - \alpha \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$

$$j = 1, \dots, n$$

Termo imposto pela  
regularização É sempre  $< 1$

# Regressão Lasso

- Ideia: em vez de penalizar os valores quadrados dos parâmetros, penaliza os **valores absolutos**

$$J(\beta) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}(i) - y^{(i)})^2 + \lambda \sum_{j=1}^n \beta_j^2 \right] \quad \textbf{Cumeeira}$$

$$J(\beta) = \frac{1}{2m} \left[ \sum_{i=1}^m (\hat{y}(i) - y^{(i)})^2 + \lambda \sum_{j=1}^n |\beta_j| \right] \quad \textbf{Laço}$$

- Tudo o resto fica na mesma!

# Regularização na regressão logística

- Função de custo:

**Regularização de cuneeira**



$$J(\beta) = \left[ -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \beta_j^2$$

$$J(\beta) = \left[ -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right] + \frac{\lambda}{2m} \sum_{j=1}^n |\beta_j|$$



**Regularização Lasso**

# Regularização na regressão logística



## Gradiente

$$\frac{\partial}{\partial \beta_0} J(\beta) \quad \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_0^{(i)}$$

$$\frac{\partial}{\partial \beta_1} J(\beta) \quad \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_1^{(i)} - \frac{\lambda}{m} \beta_1$$

$$\frac{\partial}{\partial \beta_2} J(\beta) \quad \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_2^{(i)} - \frac{\lambda}{m} \beta_2$$

(...)

(...)

$$\frac{\partial}{\partial \beta_j} J(\beta) \quad \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)} - \frac{\lambda}{m} \beta_j$$

- Rencher, A. C., C Schaalje, G. B. (2007). Linear Models in Statistics (2nd ed.) [PDF]. doi:10.1002/9780470192610
- Pillionetto, G., Chen, T., Chiuso, A., De Nicolao, G., C Ljung, L. (2022). Regularização de Modelos de Regressão Linear. Em Regularized System Identification (pp. 33-93). Springer International Publishing. [https://doi.org/10.1007/978-3-030-95860-2\\_3](https://doi.org/10.1007/978-3-030-95860-2_3)
- Tran-Dinh, Q., C van Dijk, M. (2022). Métodos do tipo gradiente descendente: Antecedentes e Análise de Convergência Unificada Simples (Versão 1). arXiv. <https://doi.org/10.48550/ARXIV.2212.09413>